

(curs 2 - S1)

2.2. Iterația de punct fix  $\rightarrow g(r) = r$

**Def 1:** Numărul real  $r$  este un punct fix al funcției  $g$  dacă  $g(r) = r$ .

2.2.1. Punctele fixe ale unei funcții

### Algoritm 1 (Iterația de punct fix)

$x_0$  = valoarea inițială

$x_{i+1} = g(x_i)$  for  $i = 0, 1, 2, \dots$

de fapt, Teorema 1 implică

$$g(r) = g\left(\lim_{i \rightarrow \infty} x_i\right) = \lim_{i \rightarrow \infty} g(x_i) = \lim_{i \rightarrow \infty} x_{i+1} = r. \quad (1)$$

### Teorema 1 (Limite continue)

Fie  $f$  o funcție continuă într-o vecinătate a lui  $x_0$ , și presupunem că  $\lim_{n \rightarrow \infty} x_n = x_0$ . Atunci

$$\lim_{n \rightarrow \infty} f(x_n) = f\left(\lim_{n \rightarrow \infty} x_n\right) = f(x_0).$$

Cu alte cuvinte, limitele pot fi introduse în interiorul funcțiilor continue.

```
function xc=fpi(g,x0,k)
    x(1)=x0;
    for i=1:k
        x(i+1)=g(x(i));
    end
    xc=x(k+1);
```

## 2.2.2. Geometria iteratiei de punct fix




Figura 1: **Geometria IPF.** Punctul fix este intersecția lui  $g(x)$  cu prima bisectoare. Trei exemple pentru  $g(x)$  sunt prezentate împreună cu primii pași ai metodei IPF. (a)  $g(x) = 1 - x^3$  (b)  $g(x) = (1 - x)^{1/3}$  (c)  $g(x) = (1 + 2x^3)/(1 + 3x^2)$

$$h = g(x) \cap x$$

- Figura 1(c) arată un exemplu de convergență foarte rapidă
- ajută această imagine în cadrul speculației?
- dacă ați ghicit că este ceva care are de a face cu panta lui  $g(x)$  în apropierea punctului fix, aveți dreptate




Figura 2: **Diagrama cobweb pentru funcții liniare.** (a) Dacă funcția liniară are panta mai mare decât 1 în valoare absolută, valori inițiale din apropierea punctului fix se depărtează de punctul fix pe măsură ce IPF progresează, ceea ce duce la eşecul metodei. (b) Pentru o pantă mai mică decât 1 în valoare absolută, are loc fenomenul invers, și punctul fix este găsit.

## 2.2.3. Convergența liniară a iteratiei de punct fix

$$a) g_1(x) = -\frac{3}{2}x + \frac{5}{2}$$

$$g_2(x) = -\frac{1}{2}x + \frac{3}{2}$$

$$|g'_1(x)| = \left| -\frac{3}{2} \right| > 1$$

$$|g'_2(x)| = \left| -\frac{1}{2} \right| < 1$$

$$h=1$$

$\Rightarrow$  valoarea lui  $|g'(r)|$  face diferența crucială între conv. și div. (perspectivă geometrică)

D.p.d.v. al ecuațiilor, este util să scriem  $g_1(x)$  și  $g_2(x)$  în funcție de  $x - h$ :

$$g_1(x) = -\frac{3}{2}(x-1) + 1$$

$$g_1(x) - 1 = -\frac{3}{2}(x-1)$$

$$x_{i+1} - 1 = -\frac{3}{2}(x_i - 1)$$

$$e_i = |h - x_i| \text{ - eroare}$$

$$\left. \begin{array}{l} \\ \end{array} \right\} \Rightarrow e_{i+1} = \frac{3e_i}{2}$$

⇒ creștere a eroarei

⇒ divergență

Analog pt  $g_2(x)$   $e_{i+1} = \frac{e_i}{2}$

⇒ descreștere a eroarei

⇒ convergență

## Definiția 2

Fie  $e_i$  eroarea la pasul  $i$  al unei metode iterative. Dacă

$$\lim_{i \rightarrow \infty} \frac{e_{i+1}}{e_i} = S < 1,$$

se spune că metoda este **liniar convergentă** cu rata  $S$ .

## Teorema 2

Să presupunem că  $g$  este o funcție derivabilă cu derivata continuă, că  $g(r) = r$ , și că  $S = |g'(r)| < 1$ . Atunci iterarea de punct fix converge liniar cu rata  $S$  la punctul fix  $r$  pentru o valoare inițială suficient de apropiată de  $r$ .

## Teorema 3 (Teorema de medie)

Fie  $f$  o funcție derivabilă cu derivata continuă pe intervalul  $[a, b]$ .

Atunci există un număr  $c$  între  $a$  și  $b$  astfel încât

$$f'(c) = (f(b) - f(a))/(b - a).$$

$$x_{i+1} - h = g'(c_i)(x_i - h) \quad c_i \in (x_i, h)$$

$$x_{i+1} = g(x_i) \quad h = g(h)$$

$$\lambda_i = |x_i - h|$$

$$\Rightarrow e_{i+1} = |g'(c_i)| e_i$$

dacă  $S = |g'(r)|$  este mai mic decât 1, atunci din continuitatea lui  $g'$ , există o vecinătate mică în jurul lui  $r$  pentru care  $|g'(x)| < (S + 1)/2$ , limită puțin mai mare decât  $S$ , dar totuși mai mică decât 1

dacă se întâmplă ca  $x_i$  să se afle în această vecinătate, atunci și  $c_i$  se află în această vecinătate (fiind situat între  $x_i$  și  $r$ ), și astfel

$$e_{i+1} \leq \frac{S+1}{2} e_i.$$

prin urmare, eroarea descrește cu un factor de  $(S + 1)/2$  sau mai bun în pasul curent și în fiecare pas viitor

$$\lim_{i \rightarrow \infty} x_i = r$$

$$\Rightarrow \lim_{i \rightarrow \infty} \frac{e_{i+1}}{e_i} = \lim_{i \rightarrow \infty} |g'(c_i)| = |g'(r)| = S$$

$$\Rightarrow e_{i+1} \approx S \cdot e_i, \quad S = |g'(r)|$$

### Definiția 3


O metodă iterativă se numește **local convergentă** la  $r$  dacă metoda converge la  $r$  pentru valori inițiale suficient de apropiate de  $r$ .

cu alte cuvinte, metoda este local convergentă la rădăcina  $r$ , dacă există o vecinătate  $(r - \epsilon, r + \epsilon)$ , unde  $\epsilon > 0$ , astfel încât convergența la  $r$  rezultă din toate valorile inițiale din vecinătate

concluzia Teoremei 2 este că iterația de punct fix este local convergentă dacă  $|g'(r)| < 1$

### Exemplul 3

- găsiți punctele fixe ale funcției  $g(x) = 2.8x - x^2$
- funcția  $g(x) = 2.8x - x^2$  are două puncte fixe 0 și 1.8, care pot fi determinate rezolvând analitic ecuația  $g(x) = x$ , sau observând unde se intersectează graficele funcțiilor  $y = g(x)$  și  $y = x$
- Figura 3 prezintă o diagramă cobweb a IPF cu valoarea inițială  $x_0 = 0.1$



**Figura 3: Diagrama cobweb pentru iterația de punct fix.** Exemplul 3 are două puncte fixe, 0 și 1.8. O iterație cu valoarea inițială 0.1 este prezentată. Iterația de punct fix va converge doar la 1.8.

pentru acest exemplu, iterațiile

$$\begin{aligned}x_0 &= 0.1000 \\x_1 &= 0.2700 \\x_2 &= 0.6831 \\x_3 &= 1.4461 \\x_4 &= 1.9579,\end{aligned}$$

pot fi citite ca intersecții de-a lungul primei bisectoare

deși punctul inițial  $x_0 = 0.1$  este în apropierea punctului fix 0, IPF se mișcă spre celălalt punct fix  $x = 1.8$  și converge acolo

diferența dintre cele două puncte fixe este că panta lui  $g$  în  $x = 1.8$ , dată prin  $g'(1.8) = -0.8$ , este mai mică decât 1 în valoare absolută

pe de altă parte, panta lui  $g$  în celălalt punct fix  $x = 0$ , cel care respinge punctele, este  $g'(0) = 2.8$ , care este mai mare decât 1 în valoare absolută

## 2.2.4. Criteriu de oprire

- spre deosebire de metoda bisecției, nr. de pași nu poate fi prescris de dimântă

→ e nevoie de un criteriu de oprire

$$|x_{i+1} - x_i| < TOL$$

sau

$$\frac{|x_{i+1} - x_i|}{|x_{i+1}|} < TOL$$

## Criteriu hibrid

$$\frac{|x_{i+1} - x_i|}{\max(|x_{i+1}|, \theta)} < TOL, \theta > 0$$

- în plus, un cod bun pentru IPF setează o limită a numărului maxim de pași în cazul în care convergența eșuează
- problema criteriului de oprire este una importantă
- metoda bisecției are o convergență liniară garantată
- iterația de punct fix este doar local convergentă, iar atunci când converge, este liniar convergentă
- ambele metode necesită o evaluare de funcție la fiecare pas
- metoda bisecției reduce incertitudinea cu un factor de 1/2 la fiecare pas, prin comparație cu aproximativ  $S = |g'(r)|$  pentru IPF
- prin urmare, iterația de punct fix poate fi mai rapidă sau mai lentă decât metoda bisecției, depinzând dacă  $S$  este mai mic sau mai mare decât 1/2
- vom studia metoda lui Newton, o versiune rafinată a IPF, unde  $S$  este proiectat să fie egal cu zero

## 2.3. Metoda lui Newton

→ denumită adesea Newton-Raphson

→ converge, de obicei, mult mai repede decât metodele liniar convergente

- perspectiva geometrică a metodei lui Newton este prezentată în Figura 4




Figura 4: Un pas pentru metoda lui Newton. Pornind de la  $x_0$ , dreapta tangentă la curba  $y = f(x)$  este trasată. Punctul de intersecție cu axa  $x$  este  $x_1$ , următoarea aproximare a rădăcinii.

→ pentru a găsi o rădăcină  $f(x) = 0$ , avem dată o valoare initială  $x_0$  și este trasată dreapta tangentă la  $f$

→ dreapta va urmări funcția până jos la axa  $x$  spre rădăcină

→  $y \cap 0_x \rightarrow$  doar o aproximare; dacă  $f$  - curbată  $\Rightarrow$  nu e exactă

→  $y$  are punctul dată de  $f'(x_0)$   $\Rightarrow A(x_0, f'(x_0)) \in y$

$$y - f(x_0) = f'(x_0)(x - x_0)$$

$$\text{Inlocuim } y=0 \rightarrow x = x_0 - \frac{f(x_0)}{f'(x_0)}$$

unde  $x =$  aproximare a rădăcinii

### Algoritm 2 (Metoda lui Newton)

$x_0$  = valoarea inițială

$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$  for  $i = 0, 1, 2, \dots$

```
newton.m
1 function xc=newton(f,dF,x0,k)
2
3 x(1)=x0;
4
5 for i=1:k
6
7     x(i+1)=x(i)-f(x(i))/df(x(i));
8
9 end
10
11 xc=x(k+1);
```

## Exemplul 4

Găsiți formula pentru metoda lui Newton în cazul ecuației

$$x^3 + x - 1 = 0$$


### Răsolvare

$$f'(x) = 3x^2 + 1$$

$$\Rightarrow x_{i+1} = x_i - \frac{x_i^3 + x_i - 1}{3x_i^2 + 1} = \frac{2x_i^3 + 1}{3x_i^2 + 1}$$

$$x_0 = -0,7 \text{ și începem să itezi } \Rightarrow x_1 \approx 0,1271$$

$$x_2 \approx 0,9577$$



**Figura 5: Trei pași din metoda lui Newton.** Ilustrarea Exemplului 4. Pornind cu  $x_0 = -0,7$ , iterațiile din metoda lui Newton sunt reprezentate grafic împreună cu dreptele tangente. Se observă că metoda converge către rădăcină.

acești pași sunt prezentate geometric în Figura 5

pașii următori sunt dați în tabelul de mai jos:

$i$	$x_i$	$e_i =  x_i - r $	$e_i/e_{i-1}^2$
0	-0.70000000	1.38232780	
1	0.12712551	0.55520230	0.2906
2	0.95767812	0.27535032	0.8933
3	0.73482779	0.05249999	0.6924
4	0.68459177	0.00226397	0.8214
5	0.68233217	0.00000437	0.8527
6	0.68232780	0.00000000	0.8541
7	0.68232780	0.00000000	

după doar șase pași, rădăcina este cunoscută cu opt zecimale exacte  
observăm în tabel că în momentul în care convergența începe să  
apără, numărul de zecimale exacte din  $x_i$  se dublează aproximativ la  
 fiecare iterație

aceasta este o caracteristică a metodelor „pătratic convergente”, după  
cum vom vedea în cele ce urmează

## 2.3.1. Convergența pătratică a metodei lui Newton

- convergența din Exemplul 4 este mai rapidă calitativ decât convergența liniară pe care am văzut-o la metoda bisecției și la iterarea de punct fix
- o nouă definiție este necesară

### Definiția 4

Fie  $e_i$  eroarea după pasul  $i$  al unei metode iterative. Iterația este **pătratic convergentă** dacă

$$M = \lim_{i \rightarrow \infty} \frac{e_{i+1}}{e_i^2} < \infty.$$

### Teorema 4 (Teorema lui Taylor cu rest)

Fie  $x$  și  $x_0$  numere reale, și fie  $f$  o funcție de  $k + 1$  ori derivabilă cu derivele continue pe intervalul dintre  $x$  și  $x_0$ . Atunci există un număr  $c$  între  $x$  și  $x_0$  astfel încât

$$\begin{aligned} f(x) &= f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \frac{f'''(x_0)}{3!}(x - x_0)^3 \\ &\quad + \cdots + \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k + \frac{f^{(k+1)}(c)}{(k+1)!}(x - x_0)^{k+1}. \end{aligned}$$

### Teorema 5

Fie  $f$  de două ori derivabilă cu derivata continuă și  $f(r) = 0$ . Dacă  $f'(r) \neq 0$ , atunci metoda lui Newton este local și pătratic convergentă la  $r$ . Eroarea  $e_i$  la pasul  $i$  satisface

$$\lim_{i \rightarrow \infty} \frac{e_{i+1}}{e_i^2} = M, \text{ unde } M = \left| \frac{f''(r)}{2f'(r)} \right|.$$

- pentru a demonstra local convergența, observăm că metoda lui Newton este o formă particulară a iterării de punct fix, unde

$$g(x) = x - \frac{f(x)}{f'(x)},$$

cu derivata

$$g'(x) = 1 - \frac{f'(x)^2 - f(x)f''(x)}{f'(x)^2} = \frac{f(x)f''(x)}{f'(x)^2}.$$

- deoarece  $g'(r) = 0$ , metoda lui Newton este local convergentă conform Teoremei 2
- pentru a demonstra convergența pătratică, deducem metoda lui Newton într-un alt mod, fiind atenți de data aceasta la eroarea de la fiecare pas
- prin eroare, înțelegem diferența dintre valoarea corectă a rădăcinii și cea mai bună aproximare curentă
- formula lui Taylor din Teorema 4 ne dă diferența dintre valorile unei funcții într-un anumit punct și un alt punct aflat în apropierea acestuia
- pentru cele două puncte, vom folosi rădăcina  $r$  și aproximarea curentă  $x_i$  după  $i$  pași, și ne vom opri și vom lua restul după doi termeni:

$$f(r) = f(x_i) + (r - x_i)f'(x_i) + \frac{(r - x_i)^2}{2}f''(c_i).$$

- aici,  $c_i$  este între  $x_i$  și  $r$
- deoarece  $r$  este rădăcina, avem că

$$\begin{aligned} 0 &= f(x_i) + (r - x_i)f'(x_i) + \frac{(r - x_i)^2}{2}f''(c_i) \\ \frac{f(x_i)}{f'(x_i)} &= r - x_i + \frac{(r - x_i)^2}{2} \frac{f''(c_i)}{f'(x_i)}, \end{aligned}$$

presupunând că  $f'(x_i) \neq 0$

- rearanjând, putem compara următoarea iterație Newton cu rădăcina:

$$\begin{aligned} x_i - \frac{f(x_i)}{f'(x_i)} - r &= \frac{(r - x_i)^2}{2} \frac{f''(c_i)}{f'(x_i)} \\ x_{i+1} - r &= e_i^2 \frac{f''(c_i)}{2f'(x_i)} \\ e_{i+1} &= e_i^2 \left| \frac{f''(c_i)}{2f'(x_i)} \right|. \end{aligned} \quad (15)$$

- în această ecuație, am definit eroarea la pasul  $i$  ca fiind  $e_i = |x_i - r|$
- deoarece  $c_i$  se află între  $r$  și  $x_i$ , acesta converge la  $r$  la fel ca  $x_i$ , și

$$\lim_{i \rightarrow \infty} \frac{e_{i+1}}{e_i^2} = \left| \frac{f''(r)}{2f'(r)} \right|,$$

adică exact definiția convergenței pătratice

- formula de eroare (15) pe care am dedus-o, poate fi văzută ca

$$e_{i+1} \approx M e_i^2, \quad (16)$$

unde  $M = |f''(r)/2f'(r)|$ , presupunând că  $f'(r) \neq 0$

- aproximarea devine mai bună pe măsură ce metoda lui Newton converge, deoarece aproximările  $x_i$  se deplasează spre  $r$ , și deoarece  $c_i$  este prins între  $x_i$  și  $r$
- această formulă de eroare trebuie comparată cu  $e_{i+1} \approx S e_i$  de la metodele liniar convergente, unde  $S = |g'(r)|$  pentru IPF și  $S = 1/2$  pentru metoda bisecției
- deși valoarea lui  $S$  este critică pentru metodele liniar convergente, valoarea lui  $M$  este mai puțin critică, deoarece formula implică pătratul erorii anterioare
- odată ce eroarea devine semnificativ mai mică decât 1, ridicarea ei la pătrat va determina o scădere suplimentară; câtă vreme  $M$  nu este foarte mare, eroarea potrivit lui (16) va descrește de asemenea
- întorcându-ne la Exemplul 4, putem analiza tabelul de ieșire pentru a demonstra această rată de eroare
- coloana din dreapta prezintă raportul  $e_i/e_{i-1}^2$ , care, conform formulei de eroare pentru metoda lui Newton (16), ar trebui să tindă la  $M$  pe măsură ce are loc convergența către rădăcină
- pentru  $f(x) = x^3 + x - 1$ , derivatele sunt  $f'(x) = 3x^2 + 1$  și  $f''(x) = 6x$ ; evaluând în  $x_c \approx 0.6823$  obținem  $M \approx 0.85$ , ceea ce este în acord cu raportul de eroare din coloana din dreapta a tabelului

## 2.3.2. Convergența liniară a metodei lui Newton

Teorema 5 nu ne spune dacă metoda lui Newton converge întotdeauna pătratic

(trebuie să împărtășim cu  $f'(r)$ )

**Exemplul 5:**

Folositi Metoda lui Newton pt. a găsi o rădăcină a lui  $f(x) = x^2$

**Rezolvare**

$$\rightarrow \boxed{x_0 = 0}$$

$$f'(x) = 2x$$

$$\rightarrow x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)} = x_i - \frac{x_i^2}{2x_i} = \frac{x_i}{2}$$

$$i=0, x_0 = 1$$

27

$i$	$x_i$	$e_i =  x_i - r $	$e_i/e_{i-1}$
0	1.000	1.000	
1	0.500	0.500	0.500
2	0.250	0.250	0.500
3	0.125	0.125	0.500
$\vdots$	$\vdots$	$\vdots$	$\vdots$

metoda lui Newton converge către rădăcina  $r = 0$

formula de eroare este  $e_{i+1} = e_i/2$ , deci convergența este liniară cu constanta de proporționalitate a convergenței  $S = 1/2$

metoda lui Newton, la fel ca IPF, s-ar putea să nu conveargă la o rădăcină

următorul exemplu prezintă doar unul dintre posibilele comportamente neconvergente ale metodei

### Exemplul 6

Aplicații Metoda lui Newton:  $f(x) = 4x^4 - 6x^2 - \frac{11}{4}$   $x_0 = \frac{1}{2}$

### Rezolvare

$f$  - cont

$$x=0 \Rightarrow f(0) < 0$$

- această funcție are rădăcini, deoarece este continuă, negativă în  $x = 0$ , și tinde la plus infinit pentru valori mari pozitive sau valori mari negative ale lui  $x$
- totuși, nicio rădăcină nu va fi găsită pentru valoarea inițială  $x_0 = 1/2$ , după cum se prezintă în Figura 6




Figura 6: Eșecul metodei lui Newton în Exemplul 6. Iterația alternează între  $1/2$  și  $-1/2$ , și nu convege către o rădăcină.

$$x_{i+1} = x_i - \frac{4x_i^4 - 6x_i^2 - \frac{11}{4}}{16x_i^3 - 12x_i}$$

$$x_1 = -\frac{1}{2}, \quad x_2 = \frac{1}{2}$$

$\rightarrow$  va alternă între aceste 2 rădăcini

- metoda lui Newton poate eșua și în alte moduri
- evident, dacă  $f'(x_i) = 0$  la orice pas al iterăției, metoda nu poate să continue
- sunt și alte exemple în care iterăția diverge la infinit sau imită un generator de numere aleatoare
- deși nu orice valoare inițială conduce la convergență către o rădăcină, Teorema 5 garantează existența unei vecinătăți de valori inițiale a fiecarei rădăcini, pentru care convergența la acea rădăcină este asigurată

## 2.4. Găsirea rădăcinilor fără derivate

- metoda lui Newton converge mai repede decât metoda bisecției și decât iterația de punct fix
- atinge această rată de convergență mai rapidă deoarece utilizează mai multe informații—în particular, informații despre dreapta tangentă la funcție, care vine din derivata funcției
- în anumite circumstanțe însă, derivata s-ar putea să nu fie disponibilă
- metoda secantei este un bun înlocuitor pentru metoda lui Newton, în acest caz
- înlocuiește dreapta tangentă cu o aproximare a acesteia, numită dreapta secantă, și converge aproape la fel de repede

→ axemântoare cu Newton

→ derivata  $\leftrightarrow$  raport de diferențe

- din punct de vedere geometric, dreapta tangentă este înlocuită cu o dreaptă care trece prin ultimele două aproximări
- punctul de intersecție al dreptei secante cu axa  $x$  este noua aproximare
- o aproximare a derivatei în punctul curent  $x_i$  este dată de raportul de diferențe

$$\frac{f(x_i) - f(x_{i-1})}{x_i - x_{i-1}}.$$

- înlocuind această aproximare pentru  $f'(x_i)$  în metoda lui Newton, obținem metoda secantei

### Algoritm 3 (Metoda secantei)

$x_0, x_1$  = valorile inițiale

$$x_{i+1} = x_i - \frac{f(x_i)(x_i - x_{i-1})}{f(x_i) - f(x_{i-1})} \text{ for } i = 1, 2, 3, \dots$$

- spre deosebire de iterația de punct fix și de metoda lui Newton, este nevoie de două valori inițiale pentru a porni metoda secantei
  - se poate demonstra că, în ipoteza că metoda secantei converge la  $r$  și  $f'(r) \neq 0$ , relația de eroare aproximativă

$$e_{i+1} \approx \left| \frac{f''(r)}{2f'(r)} \right| e_i e_{i-1}$$

are loc, și aceasta implică

$$e_{i+1} \approx \left| \frac{f''(r)}{2f'(r)} \right|^{\alpha-1} e_i^\alpha,$$

unde  $\alpha = (1 + \sqrt{5})/2 \approx 1.62$

- convergența metodei secantei către rădăcină este numită **superliniară**, ceea ce înseamnă că este între metodele liniar și pătratic convergente

```
secant.m
1 function xc = secant(f, x0, x1, k)
2 % f - function handle pentru funcția dată
3 % x0, x1 - valorile inițiale
4 % k - numărul de pași
5
6 % Inițializăm valorile inițiale
7 x(1) = x0;
8 x(2) = x1;
9
10 % Iterăm pentru k pași
11 for i = 2:k
12     x(i+1) = x(i) - (f(x(i)) * (x(i) - x(i-1))) / (f(x(i)) - f(x(i-1)));
13 end
14
15 xc = x(k+1);
16
>> f = @(x) x ^ 5 + x - 1;
>> x = secant(f, 1.6, 2.5, 10)
x =
    0.7549
```

## Exemplul 7

$$x_0 = 0, x_1 = 1, f(x) = x^3 + x - 1$$


formula devine

$$x_{i+1} = x_i - \frac{(x_i^3 + x_i - 1)(x_i - x_{i-1})}{x_i^3 + x_i - (x_{i-1}^3 + x_{i-1})}.$$

Pornind de la  $x_0 = 0$  și  $x_1 = 1$ , putem calcula

$$\begin{aligned} x_2 &= 1 - \frac{(1)(1-0)}{1+1-0} = \frac{1}{2} \\ x_3 &= \frac{1}{2} - \frac{-\frac{3}{8}(1/2-1)}{-\frac{3}{8}-1} = \frac{7}{11}, \end{aligned}$$

După cum se arată în Figura 7



**Figura 7: Doi pași din metoda secantei.** Ilustrarea Exemplului 7. Pornind de la  $x_0 = 0$  și  $x_1 = 1$ , iterările metodei secantei sunt reprezentate grafic împreună cu dreptele secante.

- următoarele iterării sunt date în tabelul de mai jos:

i	$x_i$
0	0.000000000000000
1	1.000000000000000
2	0.500000000000000
3	0.63636363636364
4	0.69005235602094
5	0.68202041964819
6	0.68232578140989
7	0.68232780435903
8	0.68232780382802
9	0.68232780382802

## Metoda falsiei pozitii $f(x)=0$

- există o generalizare a metodei secantei care este de asemenea importantă
- metoda falsiei pozitii**, sau **regula falsi**, este asemănătoare cu metoda bisecției, în care mijlocul este înlocuit cu o aproximare similară celei din metoda secantei
- dându-se un interval  $[a, b]$  în care se află o rădăcină (presupunem că  $f(a)f(b) < 0$ ), definim următorul punct

$$c = a - \frac{f(a)(a-b)}{f(a)-f(b)} = \frac{bf(a) - af(b)}{f(a)-f(b)}$$

ca în metoda secantei, dar, spre deosebire de metoda secantei, este garantat că noul punct se află în  $[a, b]$ , deoarece punctele  $(a, f(a))$  și  $(b, f(b))$  se află de părți diferite ale axei x

- noul interval, ori  $[a, c]$ , ori  $[c, b]$ , este ales depinzând dacă avem  $f(a)f(c) < 0$  sau, respectiv,  $f(c)f(b) < 0$ , și va conține în mod sigur rădăcina

#### Algoritmul 4 (Metoda falsei poziții)

Dându-se intervalul  $[a, b]$  astfel încât  $f(a)f(b) < 0$

```

for  $i = 1, 2, 3, \dots$ 
   $c = \frac{bf(a) - af(b)}{f(a) - f(b)}$ 
  if  $f(c) = 0$ , stop, end
  if  $f(a)f(c) < 0$ 
     $b = c$ 
  else
     $a = c$ 
  end
end

```

- metoda falsei poziții pare la prima vedere să fie o îmbunătățire atât a metodei bisecției cât și a metodei secantei, preluând cele mai bune proprietăți ale fiecăreia
- totuși, câtă vreme metoda bisecției garantează reducerea incertitudinii cu un factor de  $1/2$  la fiecare pas, în cazul metodei falsei poziții nu există o astfel de garanție, și pentru anumite exemple poate converge foarte încet

```

mfp.m x +
1   function xc = mfp(f, a, b, k)
2
3     if f(a) * f(b) >= 0
4       error('Nu este satisfacuta conditia f(a) * f(b) < 0')
5     end
6
7     for i = 1 : k
8
9       c = (b * f(a) - a * f(b)) / (f(a) - f(b))
10
11      if f(c) == 0
12        break;
13      end
14
15      if f(a) * f(c) < 0
16        b = c;
17      else
18        a = c
19      end
20
21    end
22
23    xc = (b * f(a) - a * f(b)) / (f(a) - f(b))

```

#### Exemplul 8

$[-1, 1], f(x) = x^3 - 2x^2 + \frac{3}{2}x$

#### Exemplul 8

- aplicați metoda falsei poziții pe intervalul inițial  $[-1, 1]$  pentru a găsi rădăcina  $r = 0$  a lui  $f(x) = x^3 - 2x^2 + \frac{3}{2}x$




Figura 8: Convergența lentă în Exemplul 8. Atât (a) metoda secantei cât și (b) metoda falsei poziții converg lent către rădăcina  $r = 0$ .

- dându-se  $x_0 = -1$ ,  $x_1 = 1$  ca interval inițial, calculăm noul punct

$$x_2 = \frac{x_1 f(x_0) - x_0 f(x_1)}{f(x_0) - f(x_1)} = \frac{1(-9/2) - (-1)1/2}{-9/2 - 1/2} = \frac{4}{5}.$$

- deoarece  $f(-1)f(4/5) < 0$ , noul interval este  $[x_0, x_2] = [-1, 0.8]$
- aceasta încheie primul pas
- observăm că incertitudinea soluției a scăzut cu mult mai puțin decât un factor de  $1/2$
- după cum arată Figura 8(b), următorii pași continuă să facă progrese lente spre rădăcina  $x = 0$