

	$X \sim N(m, \sigma^2)$	$Z \sim N(0, 1)$
Fct. de prob.	$f(x)$	$f(z) = \frac{1}{\sqrt{2\pi}} = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{z^2}{2}}$
Fct. de repartiție	$F_X(x) = P(X \leq x)$	$F_Z(z) = \Phi(z)$
Media / Dispersia	$M(X) = m$ $\sigma^2(X) = \sigma^2$	$M(Z) = 0$ , $\sigma^2(Z) = 1$ $\Phi(-z) = 1 - \Phi(z)$ $z_{1-\alpha} = -z_\alpha$ , $\Phi(z_\alpha) = \alpha$

1.  $T$  - v.a. ce înregistrează timpul dedicat unui proiect

a)  $T \sim N(m=12, \sigma^2=4)$

$P(8 \leq T \leq 16) = ?$

standardizare:

$$P(8 \leq T \leq 16) \stackrel{Z = \frac{T-m}{\sigma}}{\underset{Z \sim N(0,1)}}{=} P\left(\frac{8-12}{2} \leq \frac{T-12}{2} \leq \frac{16-12}{2}\right) = P(-2 \leq Z \leq 2) =$$

$$= \Phi_{\frac{T}{\sigma}}(2) - \Phi_{\frac{T}{\sigma}}(-2) = \Phi(2) - (1 - \Phi(2)) = 2\Phi(2) - 1 = 0,95$$

b)  $P(T > t_{\min}) = 0,95 \stackrel{?}{\Rightarrow} t_{\min} = ?$

$$P\left(\frac{T-m}{\sigma} > \frac{t_{\min}-12}{2}\right) = 0,95 \Rightarrow P\left(Z > \frac{t_{\min}-12}{2}\right) = 0,95$$

$$\Leftrightarrow 1 - P\left(Z \leq \frac{t_{\min}-12}{2}\right) = 0,95$$

$$\Leftrightarrow -\Phi\left(\frac{t_{\min}-12}{2}\right) = 0,95 - 1$$

$$\underbrace{\Phi\left(\frac{t_{\min}-12}{2}\right)}_{z_{0,05}} = 0,05 \Rightarrow \frac{t_{\min}-12}{2} = z_{0,05}$$

$$z_{0,95} = -z_{0,05} \Rightarrow z_{0,05} = -1,64 \Rightarrow$$

$$\Rightarrow t = 2 \cdot (-1,64) + 12$$

②. Punctaj - v.a ce înregistrează punctajul obținut la testul de admitere

$$\text{Punctaj} \sim N(m=500, \sigma=200)$$

$$P(\text{Punctaj} > x_{\min}) = 0,2$$

$$\xrightarrow{\text{Standardizare}} P\left(\frac{\text{Punctaj}-500}{200} > \frac{x_{\min}-500}{200}\right)$$

$$Z \sim N(0,1)$$

$$1 - \Phi\left(\frac{x_{\min}-500}{200}\right) = 0,2$$

$$\Rightarrow \Phi\left(\frac{x_{\min}-500}{200}\right) = 0,8$$

$$\frac{x_{\min}-500}{200} = 0,85 \Rightarrow x_{\min} = 500 + 200 \cdot 0,85 = 670$$

### Simularea variabilelor aleatoare

A simula o variabilă aleatoare discretă  $X$ , presupune a genera independent, conform unui algoritm, un șir de numere  $y_1, y_2, \dots, y_N$ , care să aibă particularitățile unor valori de observație asupra variabilei.

Mai precis: dacă variabila  $X$  are distribuția de probabilitate:

$$X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}$$

atunci distribuția experimentală a datelor generate trebuie să fie foarte apropiată de distribuția teoretică a variabilei  $X$ :

dacă  $nr_k$  - numărul valorilor generate, egale cu  $x_k$ ,  $k \in \{1, n\}$ , atunci  $\frac{nr_k}{N}$  trebuie să fie apropiat de  $p_k$

ex: aruncarea unei monede

$$X = \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$


$N = 100 \longrightarrow$  generăm 100 de numere de 0 și 1

$\Rightarrow$  50 de ori nr. 1

50 de ori nr. 0

$$Z = \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

$$U \sim \text{Unif}[0,1] \Rightarrow f_U(x) = \begin{cases} 1, & x \in [0,1] \\ 0, & \text{în rest} \end{cases}$$



$$F_U(x) = \begin{cases} 0, & x < 0 \\ x, & x \in [0,1] \\ 1, & x \geq 1 \end{cases}$$

$$P(c \leq U \leq d) = F_U(d) - F_U(c) = d - c \longrightarrow \text{lungimea intervalului } [c, d] \subset [0,1]$$

**Reamintim:** dacă  $U \sim \text{Unif}[0,1]$ , atunci  $(a, b] \subset [0,1]$ ,

$$P(U \in (a, b]) = b - a$$

**Exemplu:** Dacă  $A$ — eveniment  $P(A) = 0.65$  și  $B = \bar{A}$ ,  $P(B) = 0.35$ , atunci putem simula producerea unuia din cele două evenimente astfel:

- apelăm generatorul `urand()`:  
`u=urand()`;
- Dacă  $u < 0.65$ , spunem că s-a produs evenimentul  $(U < 0.65)$ ,  
 $P(U < 0.65) = P(U \in [0, 0.65]) = 0.65$ .  
 $A$  are aceeași probabilitate de realizare, deci putem considera că s-a produs evenimentul  $A$ .
- Dacă  $u \in [0.65, 1]$ , atunci s-a produs evenimentul  $(U \in [0.65, 1])$ ,  
 $P(U \in [0.65, 1]) = 1 - 0.65 = 0.35$ .  
Deci, în acest caz putem considera că s-a produs evenimentul  $B$ .

## 1. Distribuția uniformă discretă

### Propoziție


Dacă  $U \sim \text{Unif}[0,1]$  v.a. uniform distribuită pe  $[0,1]$ , iar  $n$  este număr întreg,  $n > 1$ , atunci

$$X = [nU]$$

o variabilă aleatoare discretă ce are distribuția uniformă pe mulțimea

$$b_X = \{0, 1, 2, \dots, n-1\}, \text{ adică } X = \begin{pmatrix} 0 & 1 & \dots & n-1 \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}$$

$|b_X| = n$



- $U$  ia valori în  $[0,1]$ , variabila  $nU$  ia valori în  $[0,n]$  și  $[nU] \in \{0, 1, \dots, n-1\}$ .
- 

$$P(X = k) = P([nU] = k) = P(k \leq nU < k+1)$$

$$= P\left(\frac{k}{n} \leq U < \frac{k+1}{n}\right) = P\left(U \in \left[\frac{k}{n}, \frac{k+1}{n}\right)\right) = \frac{k+1}{n} - \frac{k}{n} = \frac{1}{n}$$

```

1 Function SimDiscretU(n)
2 u=rand();
3 k=int(n*u);
4 return k;
5 end.

```

**Observație:** Înlocuind `return k;` cu `return  $x_k$ ;` se returnează o valoare de observație asupra unei variabile aleatoare discrete, uniform distribuită pe o mulțime  $\{x_0, x_1, \dots, x_{n-1}\}$ , adică asupra variabilei aleatoare:

$$X = \begin{pmatrix} x_0 & x_1 & \dots & x_{n-1} \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}$$

**Observație:** Simularea acestei variabile aleatoare este echivalentă cu simularea experimentului de extragere la întâmplare a unui element (obiect) din lista  $x_0, x_1, \dots, x_{n-1}$  și returnarea lui în "recipientul" din care a fost scos. La întâmplare înseamnă că fiecare element are aceeași șansă de a fi extras, adică probabilitatea  $1/n$ .

## Generalizare

**Algoritm ce extrage un număr la întâmplare din mulțimea de numere întregi  $\{m, m+1, \dots, n\}$ ,  $m < n$ .**

- Mulțimea conține  $N = n - m + 1$  elemente.
- Un număr selectat la întâmplare este o valoare de observație asupra variabilei aleatoare:

$$X = \begin{pmatrix} m & m+1 & \dots & n \\ \frac{1}{n-m+1} & \frac{1}{n-m+1} & \dots & \frac{1}{n-m+1} \end{pmatrix}.$$

```

1 Function randint(m,n)
2 u=rand();
3 k=int((n-m+1)*u); // k in {0, 1, 2, ..., n-m}
4 return k+m;
5 end.

```

**Aplicație: Generarea unei permutări aleatoare<sup>2</sup>**


## Simularea v.a. discrete cu o distribuție neuniformă

Fie  $X$  o v.a. discretă cu valorile ordonate, adică  $x_0 < x_1 < \dots < x_{n-1}$ .

$$X = \begin{pmatrix} x_0 & x_1 & \dots & x_{n-1} \\ p_0 & p_1 & \dots & p_{n-1} \end{pmatrix}, \quad \sum_{k=0}^{n-1} p_k = 1$$

- divizăm intervalul  $[0, 1]$ , prin punctele

$$F_0 = p_0, \quad F_1 = p_0 + p_1, \dots, F_k = p_0 + p_1 + \dots + p_k, \dots, F_{n-1} = 1$$



- Avem:

$$P(U \in (F_{k-1}, F_k]) = F_k - F_{k-1} \text{ lung.interv.} = p_k = P(X = x_k)$$

(am considerat  $F_{-1} = 0$ ).

## 2. Simularea distribuției Bernoulli

Distribuția Bernoulli  $X = \begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix}$  se simulează când avem de făcut o alegere dintre două alternative, codificate cu 1 și 0.



- se generează  $u \in [0, 1)$ , apelând  $u = \text{urand}()$ ;
  - Dacă  $u \leq p$ , atunci s-a produs evenimentul ( $U \leq p$ ),  
 $P(U \leq p) = P(0 \leq U \leq p) = p - 0 = p$  (aceeași probab. ca ( $X = 1$ )). Putem presupune că s-a produs acesta și alegem 1.
  - Dacă însă  $u > p$ , atunci facem alegerea codificată de 0.
- ```
1 Function Bernoulli(p);
2 u=urand();
3 if (u < p) return 1;
4 else return 0;
5 end
```

## 3. Simularea distribuției binomiale

Fie  $X \sim \text{Bin}(n, p)$  cu  $X = \begin{pmatrix} 0 & 1 & \dots & k & \dots & n \\ Pr_0 & Pr_1 & \dots & Pr_k & \dots & Pr_n \end{pmatrix}$

**Obs.:** se simulează conform algoritmului prezentat mai sus, singura problemă fiind calculul probabilităților  $Pr_k = P(X = k) = C_n^k p^k (1-p)^{n-k}$  și a sumelor  $F_k = Pr_0 + Pr_1 + \dots + Pr_k$ ,  $k \in \{0, n\}$ .

Folosind  $C_n^{k+1} = C_n^k \frac{n-k}{k+1}$ , avem

$$Pr_{k+1} = P(X = k+1) = C_n^{k+1} p^{k+1} (1-p)^{n-k-1} = \frac{n-k}{k+1} \frac{p}{1-p} P(X = k)$$

Notând cu  $c = \frac{p}{1-p}$ , obținem

$$Pr_{k+1} = \frac{n-k}{k+1} c Pr_k, \quad Pr_0 = (1-p)^n$$

## 4. Simularea distribuției geometrice

Fie  $X$  o variabilă aleatoare ce are distribuția geometrică de parametru

$$p \in (0, 1), X \sim \text{Geom}(p), X = \begin{pmatrix} k \\ p(1-p)^{k-1} \end{pmatrix}, \quad k \in \mathbb{N} \setminus \{0\}$$

Metoda directă de simulare= variabilă geometrică este asociată unui experiment Bernoulli:

- ```
1 FunctionGeom1(p)
2 k=0; // k contorul pentru incercarile Bernoulli
3 do {
4     u=urand()
5     k=k+1;
6 } while(u > p);
7 return k
8 end
```

**Obs.:**

- Se execută blocul de instrucțiuni din bucla do-while atâta timp cât încercările sunt un eșec.
- La primul succes returnează numărul încercării respective.
- Dacă probabilitatea succesului  $p$  este mică numărul mediu de încercări până la primul succes este mare pentru că  $M(X) = 1/p$  și în acest caz algoritmul Geom1 este ineficient.

**Propoziție**

Dacă  $p \in (0, 1)$  și  $U \sim \text{Unif}[0, 1)$ , atunci variabila aleatoare:

$$X = \left\lceil \frac{\ln(1-U)}{\ln(1-p)} \right\rceil + 1$$

are distribuția geometrică de parametru  $p$ .

Deci, pentru variabila aleatoare  $X \sim \text{Geom}(p)$ , evenimentul  $(X = k)$  are aceeași probabilitate ca evenimentul  $\left( \left\lceil \frac{\ln(1-U)}{\ln(1-p)} \right\rceil + 1 = k \right)$ ,

```

1 FunctionGeom2(p)
2 u=rand();
3 return int(log(1-u)/log(1-p)) + 1;
4 end.
```

*Demonstratie:*

$$P(X=k) = P\left[\left\lceil \frac{\ln(1-U)}{\ln(1-p)} \right\rceil + 1 = k\right] = P\left[\frac{\ln(1-U)}{\ln(1-p)} = k-1\right] =$$

$$= P\left[k-1 \leq \frac{\ln(1-U)}{\ln(1-p)} \leq (k-1)+1\right]$$

$$\begin{aligned}
& \ln(1-p) < 0 = \ln 1 \quad \left| \quad P[k \ln(1-p) < \ln(1-U) < (k-1) \ln(1-p)] = \right. \\
& 1-p < 1 \quad \left| \quad = P\left[(1-p)^k \leq 1-U < (1-p)^{k-1}\right] = \right. \\
& p > 0 \quad \left| \quad = P\left[1 - (1-p)^{k-1} < U \leq 1 - (1-p)^k\right] = \right. \\
& \quad \quad \quad = 1 - (1-p)^k - 1 + (1-p)^{k-1} = \\
& \quad \quad \quad = p(1-p)^{k-1}
\end{aligned}$$

## Simularea v.a. continue

$X$  variabila aleatoare cu o anumită distribuție de probabilitate  $\Rightarrow$  impunem condiția ca  $F_X$  - strict crescătoare pe  $I \Rightarrow \exists F_X^{-1}$

Se poate demonstra că  $U = F_X^{-1}(U)$  și  $X$  sunt identice din punct de vedere probabilistic.

$$U \xrightarrow{F_X^{-1}} Y = F_X^{-1}(U) \stackrel{\text{asem.}}{\underset{\substack{\text{d.p.d.v.} \\ \text{probabilistic}}}{=}} X$$

Dem.

Vom deduce fct. de repartiție a lui  $Y$   
(se poate nota cu  $G_Y$  această funcție)

$$G_Y(x) : P(Y \leq x) = P(F_X^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_U(F_X(x)) \\ = F_X(x)$$

$$U \sim \text{Unif}(0,1)$$

$$G_Y(x) = F_X(x) \Rightarrow X \text{ și } Y = F_X^{-1}(U) \text{ au aceeași repartiție (identice d.p.d.v. prob.)}$$

### Metoda inversării

- se aplică pentru a genera numere pseudo-aleatoare ca valori de observație asupra unei variabile aleatoare  $X$ , ce are funcția de repartiție inversabilă.
- dacă  $F_X$  este strict crescătoare, atunci ea este inversabilă.
- Pentru orice  $u \in (0,1)$ ,  $F_X^{-1}(u) \in \mathbb{R}$ .
- $u$  ca valoare de observație asupra unei variabile aleatoare  $U \sim \text{Unif}[0,1)$ ,  $x$  este valoare de observație asupra variabilei  $F_X^{-1}(U)$ .
- determinăm distribuția de probabilitate a variabilei  $Y = F_X^{-1}(U)$ :

#### Propoziție

Fie  $U \sim [0,1)$  și  $F_X$  o funcție de repartiție strict crescătoare și continuă pe intervalul de lungime minimă din  $\mathbb{R}$ , pe care variabila aleatoare  $X$  ia valori cu probabilitatea 1.

Atunci variabila aleatoare

$$Y = F_X^{-1}(U)$$

are aceeași funcție de repartiție ca și variabila  $X$ , adică  $Y$  și  $X$  sunt identic distribuite și nu se disting din punct de vedere probabilist.

Demo:  $U \sim \text{Unif}[0,1) \Rightarrow F_U(x) = x, x \in [0,1)$  și  $F_U(x) = 0$ , în rest.

Vom determina funcția de repartiție  $G_Y$  a variabilei  $Y = F_X^{-1}(U)$ :

$$G_Y(x) = P(Y \leq x) = P(F_X^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_U(F_X(x)) = F_X(x)$$


Prin urmare  $G_Y(x) = F_X(x), \forall x$ , adică funcția de repartiție a variabilei aleatoare  $Y = F_X^{-1}(U)$  este chiar  $F_X$ .

## Metoda inversării aplicate distribuției exponențiale

Fie

- Funcția de repartiție:  $F_X(x) = \begin{cases} 0 & \text{dacă } x < 0 \\ 1 - e^{-x/\theta} & \text{dacă } x \geq 0 \end{cases}$

$$\lim_{x \rightarrow \infty} F_X(x) = 1$$



- $F_X$  este strict crescătoare pe intervalul  $[0, \infty)$
- $\forall u \in [0, 1), F^{-1}(u) \in [0, \infty)$ .
- O v. a. exponențial distribuită ia valori pozitive cu probabilitatea 1:  
 $P(X \geq 0) = 1 - P(X < 0) = 1 - F_X(0) = 1 - 0 = 1$
- prin metoda inversării putem simula  $X$ .
- Din  $1 - e^{-x/\theta} = u$ , avem  $x = F^{-1}(u) = -\theta \ln(1 - u)$