

# Curs 11: Lanțuri Markov. Definiție, proprietăți, simulare

## 1.1 Lanțuri Markov: generalități

Lanțurile Markov se folosesc în modelarea și simularea unor sisteme în care se produc anumite evenimente la momente discrete de timp  $t = 0, 1, 2, \dots$ . Astfel de lanțuri se folosesc în design-ul algoritmilor de rutare, al protocoalelor pentru rețele wireless, în controlul mișcării roboților, ranking-ul paginilor WEB și al echipelor sportive, în analiza protocoalelor de management a memoriei, studiul performanței serverelor, în algoritmi randomizați, în machine learning (de exemplu, în computational advertising) etc. Există chiar și un limbaj de modelare pentru sisteme hardware/software în timp real, numit *POOSL*, *Parallel Object Oriented Specification Language*, care generează un lanț Markov, ca model al sistemului.

Un sistem este reprezentat de o mulțime finită de stări (noduri)  $S = \{1, 2, \dots, m\}$  sau infinit numărabilă  $S = \mathbb{N}$ . Mulțimea  $S$  se numește spațiul stărilor sau al nodurilor unei rețele. Schimbările de stare se produc la întâmplare, la momente discrete de timp  $t = 0, 1, 2, \dots, n, \dots$ . În continuare vom discuta preponderent exemple în care la momente discrete de timp se produce o transmitere de informație de la un nod din rețea spre altul sau "un călător virtual" trece de la un nod spre altul. Nodul spre care se transmite informația (sau nodul în care trece călătorul) depinde de diverse circumstanțe și astfel informația (călătorul) are o traiectorie aleatoare în rețea.

Fiecărui moment de timp  $n \in \mathbb{N}$  i se asociază o variabilă aleatoare  $X_n$  ce ia valori în mulțimea nodurilor:

$$X_n = \begin{pmatrix} 1 & 2 & \dots & m \\ \pi_n(1) & \pi_n(2) & \dots & \pi_n(m) \end{pmatrix},$$

unde  $\pi_n(i)$  este probabilitatea ca la momentul  $n$  informația să atingă (să ajungă) în nodul  $i \in S$ .

**Definiția 1.1.1** Un șir de variabile aleatoare  $(X_n)$ ,  $n \in \mathbb{N}$ , definite pe același spațiu de probabilitate  $(\Omega, \mathcal{K}, P)$  cu valori în mulțimea stărilor (nodurilor)  $S$ , definește un *lanț Markov* dacă probabilitatea ca informația să treacă la momentul  $n + 1$  în nodul  $j$  știind

că în momentele de timp anterioare se afla respectiv în nodurile  $s_0, s_1, \dots, s_{n-1}$ ,  $i$  este

$$P(X_{n+1} = j | X_0 = s_0, X_1 = s_1, \dots, X_{n-1} = s_{n-1}, X_n = i) = P(X_{n+1} = j | X_n = i). \quad (1)$$

Probabilitatea  $P(X_{n+1} = j | X_n = i)$  se citește ”probabilitatea ca informația să treacă în nodul  $j$  la momentul  $n + 1$ , știind că se află în nodul  $i$  la momentul  $n$ ”. Relația (1) se numește *proprietate markoviană*. Aceasta caracterizează ”lipsa parțială de memorie” a lanțului Markov: cunoscând succesiunea de noduri  $s_0, s_1, \dots, s_{n-1}, i$ , prin care informația a trecut până la momentul prezent  $n$ , doar nodul  $i$ , în care se află în prezent, influențează probabilitatea de trecere în momentul următor într-un alt nod, nu și drumul parcurs până la momentul curent  $n$  (cu alte cuvinte doar istoria recentă, nu și cea trecută, influențează evoluția viitoare).

În mod normal probabilitățile  $P(X_{n+1} = j | X_n = i)$  depind de  $n$ , adică

$$P(X_{n+1} = j | X_n = i) = p_{ij}(n).$$

Un lanț Markov  $(X_n)$  se numește *omogen*, dacă probabilitățile  $P(X_{n+1} = j | X_n = i)$  nu depind de  $n$ .

În continuare ne referim la lanțuri Markov omogene cu o mulțime finită de stări, iar în loc de trecerea informației sau a călătorului virtual de la un nod la altul, spunem trecerea lanțului Markov.

Pentru un lanț Markov omogen, notăm cu  $p_{ij} = P(X_{n+1} = j | X_n = i)$ ,  $i, j = \overline{1, m}$ , probabilitatea ca la momentul  $n + 1$  lanțul Markov să treacă în nodul  $j$ , știind că la momentul  $n$  se afla în nodul  $i$ .  $p_{ij}$  se numește probabilitate de trecere într-un singur pas din nodul  $i$  în nodul  $j$ , iar matricea  $Q$ , de elemente  $Q(i, j) := p_{ij}$ ,  $i, j = \overline{1, m}$ , se numește *matricea de tranziție a lanțului Markov*.

În concluzie, un lanț Markov definește o lege de mișcare la întâmplare pe mulțimea nodurilor.

Matricea de tranziție  $Q = (p_{ij})_{i,j \in S}$  are proprietățile:

1.  $p_{ij} \geq 0, \forall (i, j) \in S \times S$ ;
2.  $\sum_{j=1}^m p_{ij} = 1, \forall i \in S$ , adică suma elementelor de pe fiecare linie este 1.

O astfel de matrice se numește *matrice stohastică*, iar liniile ei se numesc *vectori stohastici* sau *vectori probabiliști*. Elementele de pe linia  $i$ ,  $i = \overline{1, m}$ , a matricei  $Q$ ,  $p_{i1}, p_{i2}, \dots, p_{im}$ , indică probabilitățile ca din starea  $i$  lanțul Markov să treacă respectiv în stările  $1, 2, \dots, m$ .

### Proprietăți ale matricelor stohastice

- Notăm cu  $\mathbf{e}$  vectorul care are toate coordonatele egale cu 1, adică  $\mathbf{e} = [1, 1, \dots, 1]^T$ .

Astfel produsul  $Q\mathbf{e}$  este:

$$\begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1m} \\ & & \vdots & \\ p_{k1} & p_{k2} & \cdots & p_{km} \\ & & \vdots & \\ p_{m1} & p_{m2} & \cdots & p_{mm} \end{pmatrix} \begin{pmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} p_{11} + p_{12} + \cdots + p_{1m} \\ \vdots \\ p_{k1} + p_{k2} + \cdots + p_{km} \\ \vdots \\ p_{m1} + p_{m2} + \cdots + p_{mm} \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Această relație ne permite exprimarea concentrată a proprietății lui  $Q$  de a avea toate liniile vectori stochastici:

$$Q\mathbf{e} = \mathbf{e}.$$

Relația de mai sus exprimă și faptul că  $\mathbf{e}$  este vector propriu al matricei  $Q$ , corespunzător valorii proprii  $\lambda = 1$ . În continuare o vom folosi ca relație de definiție a unei matrice stochastice (subînțelegând că elementele ei sunt mai mari sau egale cu zero).

- Produsul a două matrice stochastice  $P, Q$  este o matrice stohastică, deoarece  $P\mathbf{e} = \mathbf{e}$  și  $Q\mathbf{e} = \mathbf{e}$  implică  $(PQ)\mathbf{e} = P(Q\mathbf{e}) = P\mathbf{e} = \mathbf{e}$ .

Ca o consecință a acestei proprietăți rezultă că dacă  $Q$  este matricea de tranziție a unui lanț Markov, atunci  $Q^n$  este matrice stohastică,  $\forall n \in \mathbb{N}$ .

- Dacă  $P, Q$  sunt matrice stochastice și  $\alpha \in (0, 1)$ , atunci combinația convexă

$$M = \alpha P + (1 - \alpha)Q$$

este o matrice stohastică.

Mulțimea nodurilor unui lanț Markov și matricea de tranziție definesc un graf orientat. Există arc orientat de la  $i$  la  $j$ , dacă probabilitatea  $p_{ij}$  este nenulă. Graful astfel asociat se numește *graf de tranziție al lanțului Markov*.

**Exemplul 1.** Fie  $S = \{1, 2, 3\}$  mulțimea nodurilor unei rețele și  $Q$  matricea de tranziție de la un nod la altul:


$$Q = \begin{pmatrix} 0.4 & 0.5 & 0.1 \\ 0.2 & 0.7 & 0.1 \\ 0.4 & 0.4 & 0.2 \end{pmatrix}.$$

Graful asociat este vizualizat în Fig. 1.

### 1.1.1 Simularea unui lanț Markov

**O realizare a lanțului Markov** ( $X_n$ ) sau o observație asupra lanțului este un șir de noduri ce pot fi vizitate de lanț,  $(s_0, s_1, \dots, s_n, \dots)$ ,  $s_k \in S$ , și se numește **traietorie a lanțului Markov**.

Pentru a putea analiza și simula un lanț Markov, trebuie precizată **distribuția inițială de probabilitate**, care dă probabilitatea ca traectoria aleatoare a lanțului să pornească



**Fig.1:** Graful de tranziție al unui lanț Markov. Pe fiecare arc este indicată probabilitatea de trecere între nodurile conectate de arc.

dintr-un nod  $i$ . Mai precis, distribuția inițială de probabilitate este un vector probabilist (vector cu coordonatele în  $[0,1]$  și suma coordonatelor egală cu 1):

$$\pi_0 = [\pi_0(1), \pi_0(2), \dots, \pi_0(m)]^T, \quad \pi_0(k) \geq 0, \quad \sum_{k=1}^m \pi_0(k) = 1,$$

unde  $\pi_0(k) = P(X_0 = k)$  este probabilitatea ca la momentul  $t = 0$  lanțul să pornească din nodul  $k$ . Cu alte cuvinte, distribuția inițială de probabilitate a lanțului Markov este distribuția de probabilitate a variabilei aleatoare discrete  $X_0$ :

$$X_0 = \begin{pmatrix} 1 & 2 & \dots & m \\ \pi_0(1) & \pi_0(2) & \dots & \pi_0(m) \end{pmatrix}. \quad (2)$$

Dacă distribuția inițială de probabilitate este, de exemplu,  $\pi_0 = [0, 1, 0, \dots, 0]^T$ , atunci spunem că lanțul pornește sigur (adică cu probabilitatea 1) din nodul 2.

Dacă pentru lanțul Markov din Exemplul 1 distribuția inițială de probabilitate este

$$X_0 = \begin{pmatrix} 1 & 2 & 3 \\ 0.2 & 0.5 & 0.3 \end{pmatrix},$$

atunci înseamnă că probabilitatea ca un mers (drum) aleator în mulțimea  $S = \{1, 2, 3\}$  să pornească, de exemplu, din starea 2 este 0.5.

Un lanț Markov este simulat în mod iterativ. **Algoritmul de simulare a unui LM** este prototip pentru *clasa algoritmilor iterativi aleatori*. Având dat spațiul stărilor  $S = \{1, 2, \dots, m\}$ , distribuția inițială de probabilitate  $\pi_0 = [\pi_0(1), \pi_0(2), \dots, \pi_0(m)]^T$  și matricea de tranziție  $Q = (p_{ij})$ ,  $i, j = \overline{1, m}$ , pentru un lanț Markov  $(X_n)$ , putem genera o traiectorie aleatoare  $s_0, s_1, \dots, s_n$  astfel:

- Construim simulatorul unei variabile aleatoare discrete arbitrare:

$$Y = \begin{pmatrix} 1 & 2 & \dots & m \\ p_1 & p_2 & \dots & p_m \end{pmatrix},$$

pe care îl notăm simbolic cu

$$\text{simulator}(1, 2, \dots, m; \mathbf{p}),$$

unde  $\mathbf{p}$  este vectorul de probabilitate al variabilei  $Y$ . Prin  $j = \text{simulator}(1, 2, \dots, m; \mathbf{p})$  simbolizăm faptul că simulatorul generează numărul (starea)  $j$ .

• Se generează starea inițială  $s_0$ , din care pornește traiectoria, simulând variabila aleatoare  $X_0$  definită în (2).

Probabilitățile de trecere din starea  $i = s_0$  în una din stările sistemului sunt date de elementele din linia  $i$  a matricei de tranziție  $Q = (p_{ij})$ . Astfel starea  $s_1$  la momentul  $t = 1$  este o observație asupra variabilei aleatoare discrete

$$T_1 = \begin{pmatrix} 1 & 2 & \dots & m \\ Q_{i1} & Q_{i2} & \dots & Q_{im} \end{pmatrix},$$

ce ia valorile  $\{1, 2, \dots, m\}$  cu probabilitățile din linia  $i$  a matricei de tranziție etc.

Algoritmul de generare a segmentului de traiectorie  $\mathbf{s}_0, \mathbf{s}_1, \dots, \mathbf{s}_n$  este:

```

1: function LantMarkov(m,  $\pi_0$ , Q, n)
2:    $\mathbf{s}_0 = \text{simulator}(1, 2, \dots, m; \pi_0)$ ;
3:    $\mathbf{i} = \mathbf{s}_0$ ;
4:   for k = 1 : n
5:      $\mathbf{p} = Q[\mathbf{i}, :]; // Q[\mathbf{i}, :] = [\text{linia } \mathbf{i} \text{ din matricea } Q]$ ;
6:      $\mathbf{s}_k = \text{simulator}(1, 2, \dots, m; \mathbf{p})$ ;
7:      $\mathbf{i} = \mathbf{s}_k$ ;
8:   end for
9:   return  $\mathbf{s}_0, \mathbf{s}_1, \dots, \mathbf{s}_n$ ;
10: end function
```

### 1.1.2 Analiza unui lanț Markov

Pe lângă tranziția într-un singur pas a unui lanț Markov, suntem interesați și de tranziția dintr-un nod în altul în  $n$  pași. Fie

$$P(X_n = j | X_0 = i), \quad i, j \in S,$$

probabilitatea ca lanțul să treacă din nodul inițial  $i$  în nodul  $j$  după  $n$  pași. Să arătăm că această probabilitate este dată de elementul din poziția  $(i, j)$  a matricei de tranziție  $Q$  la puterea  $n$ , notat cu  $Q^n(i, j)$ .

**Propoziția 1.1.1** *Are loc:*

$$P(X_n = j | X_0 = i) = Q^n(i, j).$$

**Demonstrație:** Vom arăta mai întâi că  $P(X_2 = j|X_0 = i) = Q^2(i, j)$ . Evenimentul  $(X_2 = j|X_0 = i)$  se poate scrie astfel:

$$(X_2 = j|X_0 = i) = \bigcup_{k=1}^m (X_2 = j, X_1 = k|X_0 = i),$$

deci

$$\begin{aligned} P(X_2 = j|X_0 = i) &= \frac{\sum_{k=1}^m P(X_0 = i, X_1 = k, X_2 = j)}{P(X_0 = i)} \\ &= \frac{\sum_{k=1}^m P(X_0 = i)P(X_1 = k|X_0 = i) \underbrace{P(X_2 = j|X_0 = i, X_1 = k)}_{P(X_2=j|X_1=k)}}{P(X_0 = i)} \\ &= \sum_{k=1}^m Q(i, k)Q(k, j) = Q^2(i, j). \end{aligned}$$

Presupunem că egalitatea  $P(X_{n-1} = j|X_0 = i) = Q^{n-1}(i, j)$  este adevărată. Pentru a o demonstra și în cazul  $n$ , exprimăm evenimentul

$$(X_n = j|X_0 = i) = \bigcup_{k=1}^m (X_n = j, X_{n-1} = k|X_0 = i).$$

Procedând la fel ca în cazul  $n = 2$  se obține concluzia. □

Are loc:

$$Q^n(i, j) = P(X_n = j|X_0 = i) = P(X_{n+k} = j|X_k = i), \text{ pentru orice } k \in \mathbb{N}.$$

Deci, probabilitatea de a trece în  $n$  pași din nodul  $i$  în nodul  $j$  nu depinde de momentul în care lanțul este în nodul  $i$ .

Pentru a putea face predicții asupra traiectoriei aleatoare definite de lanț să calculăm câteva probabilități ale unor evenimente de interes.

**Propoziția 1.1.2** *Probabilitatea ca lanțul să evolueze pe traiectoria  $s_0, s_1, s_2, \dots, s_n$  este:*

$$P(X_0 = s_0, X_1 = s_1, \dots, X_{n-1} = s_{n-1}, X_n = s_n) = \pi_0(s_0)Q(s_0, s_1)Q(s_1, s_2) \cdots Q(s_{n-1}, s_n).$$

**Demonstrație:** Din formula condiționării iterate și a proprietății markoviene (1) avem

$$\begin{aligned} &P(X_0 = s_0, X_1 = s_1, \dots, X_{n-1} = s_{n-1}, X_n = s_n) \\ &= P(X_0 = s_0)P(X_1 = s_1|X_0 = s_0)P(X_2 = s_2|X_0 = s_0, X_1 = s_1) \cdots \\ &\quad \cdots P(X_n = s_n|X_0 = s_0, X_1 = s_1, \dots, X_{n-1} = s_{n-1}) \\ &= \pi_0(s_0)P(X_1 = s_1|X_0 = s_0)P(X_2 = s_2|X_1 = s_1) \cdots P(X_n = s_n|X_{n-1} = s_{n-1}) \\ &= \pi_0(s_0)Q(s_0, s_1)Q(s_1, s_2) \cdots Q(s_{n-1}, s_n). \end{aligned}$$

□

**Exemplul 2.** Considerăm lanțul Markov din Exemplul 1, având distribuția inițială de probabilitate  $\pi_0 = [0.2, 0.5, 0.3]^T$ . Să se calculeze probabilitatea ca lanțul să evolueze din starea  $s_0 = 2$  în starea  $s_4 = 1$  pe traiectoria 2, 1, 3, 2, 1.

Conform formulei deduse, probabilitatea ca lanțul să aibă traiectoria 2, 1, 3, 2, 1 este

$$P = \pi_0(2)Q(2,1)Q(1,3)Q(3,2)Q(2,1) = 0.5 \times 0.2 \times 0.1 \times 0.4 \times 0.2 = 0.0008.$$

### Distribuția de probabilitate a variabilei de stare la momentul $n$

În definiția unui lanț Markov  $(X_n)$  nu se precizează și distribuția de probabilitate a variabilei aleatoare de stare  $X_n$ . Variabila aleatoare  $X_n$  ia valorile  $\{1, 2, \dots, m\}$  și evenimentul  $(X_n = j)$  este evenimentul ca la momentul  $n$  traiectoria aleatoare să ajungă în nodul  $j \in S$ . Notăm cu  $\pi_n(j) = P(X_n = j)$ .

Vom arăta că dacă se cunoaște distribuția inițială de probabilitate  $\pi_0$  și matricea de tranziție  $Q$  a lanțului Markov  $(X_n)$ , atunci putem determina și distribuția de probabilitate  $\pi_n = [\pi_n(1), \pi_n(2), \dots, \pi_n(m)]^T$  a variabilei aleatoare  $X_n$ ,  $\forall n \in \mathbb{N}^*$ .

**Propoziția 1.1.3** *Distribuția de probabilitate a stării la momentul  $n$  este:*

$$\pi_n^T = \pi_0^T Q^n \quad (3)$$

sau detaliat:

$$\begin{bmatrix} \pi_n(1) & \pi_n(2) & \dots & \pi_n(m) \end{bmatrix} = \begin{bmatrix} \pi_0(1) & \pi_0(2) & \dots & \pi_0(m) \end{bmatrix} Q^n.$$

**Observație** Vectorii probabiliști  $\pi_0, \pi_n$  sunt matrice coloană, deci transpusele lor sunt matrice linie

**Demonstrație:** Notăm cu  $A$  evenimentul  $(X_n = j)$  și cu  $H_i$  evenimentele (ipoteze)  $H_i = (X_0 = i)$ ,  $i = 1, 2, \dots, m$ . Evident că  $H_1, H_2, \dots, H_m$  constituie o descompunere a evenimentului sigur în  $m$  evenimente mutual exclusive două câte două. Conform formulei probabilității totale avem:

$$P(A) = \sum_{i=1}^n P(H_i)P(A|H_i).$$

Rescriem formula probabilității totale înlocuind  $A$  cu  $(X_n = j)$  și  $H_i$  cu  $(X_0 = i)$ :

$$P(X_n = j) = \sum_{i=1}^m P(X_0 = i)P(X_n = j|X_0 = i),$$

adică

$$P(X_n = j) = \sum_{i=1}^m \pi_0(i)Q^n(i, j).$$

Rezultă astfel că

$$\pi_n(j) = \sum_{i=1}^m \pi_0(i) Q^n(i, j),$$

ceea ce ne conduce la relația matriceală

$$[\pi_n(1) \ \pi_n(2) \ \dots \ \pi_n(m)] = [\pi_0(1) \ \pi_0(2) \ \dots \ \pi_0(m)] Q^n$$

sau concentrat

$$\pi_n^T = \pi_0^T Q^n.$$

□

Din relația (3) rezultă că distribuția de probabilitate  $X_n$  a stării la momentul  $n$  se poate calcula recursiv pornind de la distribuția inițială  $\pi_0$ :

$$\begin{aligned} \pi_1^T &= \pi_0^T Q \\ \pi_2^T &= \pi_0^T Q^2 = \pi_1^T Q \\ &\vdots \\ \pi_n^T &= \pi_{n-1}^T Q, \ n \in \mathbb{N}^*. \end{aligned} \tag{4}$$

**Exemplul 3.** Pentru lanțul Markov dat în Exemplul 1, considerând distribuția inițială de probabilitate  $\pi_0 = [0.2, 0.35, 0.45]^T$ , distribuțiile de probabilitate ale variabilelor aleatoare (stărilor)  $X_1, X_2, \dots, X_{10}$ , calculate conform relației de recurență de mai sus, sunt:

$$\begin{aligned} \pi_1 &= [0.330000000000 \quad 0.525000000000 \quad 0.145000000000]^T \\ \pi_2 &= [0.295000000000 \quad 0.590500000000 \quad 0.114500000000]^T \\ \pi_3 &= [0.281900000000 \quad 0.606650000000 \quad 0.111450000000]^T \\ \pi_4 &= [0.278670000000 \quad 0.610185000000 \quad 0.111145000000]^T \\ \pi_5 &= [0.277963000000 \quad 0.610922500000 \quad 0.111114500000]^T \\ \pi_6 &= [0.277815500000 \quad 0.611073050000 \quad 0.111111450000]^T \\ \pi_7 &= [0.277785390000 \quad 0.611103465000 \quad 0.111111145000]^T \\ \pi_8 &= [0.27777930700 \quad 0.611109578500 \quad 0.111111114500]^T \\ \pi_9 &= [0.27777808430 \quad 0.611110804250 \quad 0.111111111450]^T \\ \pi_{10} &= [0.27777783915 \quad 0.611111049705 \quad 0.111111111145]^T. \end{aligned}$$

Faptul că matricei de tranziție  $Q$  și distribuției inițiale de probabilitate  $\pi_0$  li se asociază un șir de vectori probabiliști  $(\pi_n)$ , ne conduce la întrebările:

- În ce condiții este șirul  $(\pi_n)$  convergent?
- Dacă șirul  $(\pi_n)$  este convergent la  $\pi$ , ce reprezintă limita sa  $\pi$ ?
- Fiecare distribuție inițială  $\pi_0$  definește un alt șir  $(\pi_n)$  prin  $\pi_n^T = \pi_0^T Q^n$ . Ne așteptăm ca în caz de convergență să obținem mereu altă limită?

Pentru a răspunde acestor întrebări detaliem câteva particularități ale matricei  $Q$  și a transpusei sale  $Q^T$ , precum și ale șirului  $(\pi_n)$ .



**Propoziția 1.1.4** Dacă șirul  $(\pi_n)$  al distribuțiilor de stare este convergent, atunci limita sa este un vector probabilist  $\pi$ , adică un vector de coordonate mai mari sau egale cu zero și suma coordonatelor este 1.

**Demonstrație:** Fie  $\pi_n = [\pi_n(1), \pi_n(2), \dots, \pi_n(m)]^T$  cu  $\pi_n(i) \in [0, 1]$  și  $\sum_{i=1}^m \pi_n(i) = 1$ .

Presupunem că șirul vectorial  $(\pi_n)$  este convergent la vectorul  $\pi = [\pi_1, \pi_2, \dots, \pi_m]^T$ . Se știe din analiză că  $\pi_n \rightarrow \pi$  dacă și numai dacă  $\pi_n(i) \rightarrow \pi_i$ ,  $\forall i = 1, 2, \dots, m$ . Astfel, șirul  $S_n = \pi_n(1) + \pi_n(2) + \dots + \pi_n(m) \rightarrow \pi_1 + \pi_2 + \dots + \pi_m$ . Dar  $S_n = 1$  pentru orice  $n$ , deci și limita sa este 1, adică  $\pi_1 + \pi_2 + \dots + \pi_m = 1$  (ceea ce evidențiază că  $\pi$  este vector probabilist).  $\square$

**Propoziția 1.1.5** Dacă șirul  $(\pi_n)$  al distribuțiilor de stare la momentul  $n$  converge la  $\pi$ , atunci are loc:

$$\pi^T = \pi^T Q. \quad (5)$$

**Demonstrație:** Dacă  $\lim_{n \rightarrow \infty} \pi_n = \pi$ , atunci și  $\lim_{n \rightarrow \infty} \pi_{n-1} = \pi$ . Trecând la limită când  $n \rightarrow \infty$  în relația

$$\pi_n^T = \pi_{n-1}^T Q,$$

obținem (5).  $\square$

**Definiția 1.1.2** O distribuție de probabilitate  $\pi$ , pe spațiul nodurilor unui lanț Markov, cu proprietatea că  $\pi^T = \pi^T Q$  se numește *distribuție invariantă, staționară sau distribuție de echilibru*.

Ce înseamnă asta?

Din faptul că  $\pi$  este limita șirului  $(\pi_n)$  rezultă că pentru orice  $\varepsilon > 0$  există un rang  $N(\varepsilon)$  astfel încât pentru orice  $n \geq N(\varepsilon)$  avem  $\|\pi_n - \pi\| < \varepsilon$ , adică dacă se calculează  $\pi_n$ , pentru  $n$  suficient de mare, cu ajutorul relației  $\pi_n^T = \pi_0^T Q^n$ , atunci  $\pi_n$  aproximează destul de bine limita  $\pi$  și deci de la un anumit rang avem că  $\pi_{n+1}^T = \underbrace{\pi_n^T}_{\approx \pi^T} Q \approx \pi^T$  etc.

Dacă există distribuția de echilibru  $\pi = [\pi(1), \pi(2), \dots, \pi(m)]^T$  (ca limită a șirului  $\pi_n$ ), atunci  $\pi(j)$  reprezintă șansa asimptotică de a fi vizitat nodul  $j$ . Cu alte cuvinte, dacă mișcarea aleatoare pe  $S$  continuă indefinit și șirul  $(\pi_n)$  este convergent, atunci de la un moment dat mișcarea aleatoare se stabilizează și vizitează fiecare nod  $j \in \{1, 2, \dots, m\}$  cu aceeași frecvență  $\pi(j)$ .

În cazul Exemplului 3 dacă veți calcula distribuțiile de probabilitate  $\pi_{50}, \pi_{51}, \dots, \pi_{100}$  și afișați coordonatele cu 15 zecimale, veți obține

$$\pi_{50} = \pi_{51} = \dots = \pi_{100} = [0.277777777778 \quad 0.611111111111 \quad 0.111111111111]^T.$$

Observăm că  $P(X_{50} = k) = \dots = P(X_{100} = k)$ , pentru  $k = 1, 2, 3$ . Orice distribuție de probabilitate  $\pi_n$ , cu  $n \geq 50$ , am calcula cu 15 zecimale am obține distribuții identice

cu  $\pi_{50}$ , adică după momentul  $n = 50$  distribuția este staționară, nu se mai modifică în primele 15 zecimale și deci sistemul a ajuns într-un echilibru.

De-a lungul oricărei traiectorii începând cu momentul  $n = 50$ ,  $s_{50}, s_{51}, \dots, s_{50+N}$ , de lungime  $N + 1$ , starea 1 este "vizitată" de lanțul Markov în proporție de  $100 \pi(1)\% = 27.7777777778\%$ , starea 2 în proporție de  $100 \pi(2)\% = 61.1111111111\%$ , iar starea 3 în proporție de  $100 \pi(3)\% = 11.1111111111\%$ . Mai mult, observăm că pentru  $n > 50$  norma diferenței dintre două distribuții consecutive  $\pi_n - \pi_{n-1}$  este mai mică decât  $10^{-15}$ , adică  $\|\pi_n - \pi_{n-1}\| < 10^{-15}$ .

## 1.2 Lanțuri Markov ireductibile și aperiodice

Ne întrebăm acum în mod natural, ce anume proprietăți ale lanțului Markov asigură convergența șirului de distribuții  $(\pi_n)$ ? Dacă lanțul Markov ar fi definit pe nodurile grafului WEB (ce constă din paginile WEB) și mișcarea aleatoare s-ar face alegând din fiecare pagină cu o anumită probabilitate paginile către care există linkuri, atunci existența distribuției de echilibru ar permite caracterizarea popularității paginilor WEB cu ajutorul distribuției  $\pi$ ,  $\pi(j)$  reprezentând frecvența asimptotică cu care un navigator aleator pe WEB ar vizita pagina  $j$ , adică popularitatea paginii  $j$ .

În continuare prezentăm condițiile pe care trebuie să le îndeplinească graful de tranziție al unui lanț Markov pentru ca șirul distribuțiilor  $(\pi_n)$  să fie convergent. Particularitățile pe care le evidențiem sunt cele care au inspirat modul de definire a navigării aleatoare de către Larry Page și Serghei Brin, fondatorii motorului de căutare Google și autorii PageRank-ului.

**Definiția 1.2.1** Un lanț Markov pe  $S = \{1, 2, \dots, m\}$  se numește *lanț ireductibil*, dacă pentru oricare două noduri  $i, j \in S$  există  $n = n(i, j) \in \mathbb{N}^*$  astfel încât  $Q^n(i, j) > 0$ , adică cu probabilitate nenulă lanțul Markov poate trece într-un număr de pași din nodul  $i$  în nodul  $j$ .

Practic lanțul este ireductibil dacă și numai dacă graful de tranziție este tare conex (există drum de arce între orice două noduri).

Dacă matricea de tranziție are toate elementele  $Q(i, j) > 0$ ,  $\forall i, j \in \overline{1, m}$ , atunci lanțul Markov este ireductibil.


**Exemplul 4.** Lanțul Markov având spațiul stărilor  $S = \{1, 2, 3, 4\}$  și matricea de tranziție:

$$Q = \begin{pmatrix} 0.35 & 0.65 & 0 & 0 \\ 0.45 & 0.55 & 0 & 0 \\ 0 & 0 & 0.6 & 0.4 \\ 0 & 0 & 0.2 & 0.8 \end{pmatrix}$$

nu este un lanț ireductibil, așa cum se poate observa mai simplu din graful asociat. Mulțimile de stări  $\{1, 2\}$  și  $\{3, 4\}$  nu comunică între ele.

**Observația 1.2.1** *Simplul fapt că  $Q(i, j) = 0$  nu asigură că  $i$  nu comunică cu  $j$ . Cele două noduri nu comunică într-un pas, dar pot comunica în mai mulți pași, adică s-ar putea ca  $Q^n(i, j) > 0$ , pentru un  $n > 1$ .*

Un lanț Markov poate avea și *traectorii periodice* (Fig. 2), adică traectorii în care succesiunea de noduri  $s_0, s_1, \dots, s_{T-1}, s_T = s_0$  se repetă indefinit într-o traectorie a lanțului.



**Fig.2:** Graful de tranziție al unui lanț Markov ce are traectoria periodică (1,3,4,1)

Din analiza grafului din figură rezultă că probabilitățile  $Q^3(1, 1) > 0$ ,  $Q^6(1, 1) > 0$  și în general  $Q^{3k}(1, 1) > 0$ ,  $\forall k \in \mathbb{N}^*$ , deci cu o probabilitate pozitivă, o traectorie ce pornește din 1 se reîntoarce în 1 după 3 pași, 6 pași sau mai general un multiplu de 3 pași. Această proprietate indică faptul că traectoria ce pornește din 1 este periodică. Analog pentru 3 și 4.

**Definiția 1.2.2** *Perioada unui nod  $i \in S$  este numărul*

$$\tau_i = c.m.m.d.c. \{n \in \mathbb{N}^* \mid Q^n(i, i) > 0\}.$$

În cazul exemplului nostru cel mai mare divizor comun al numerelor de forma  $3k$ ,  $k \in \mathbb{N}^*$ , este 3, deci nodul 1 este periodic de perioadă 3 și analog nodurile 3 și 4.

Un nod  $i$  a cărui perioadă este 1, adică nodul pentru care cel mai mare divizor comun al numerelor  $n \in \mathbb{N}^*$  cu proprietatea că  $Q^n(i, i) > 0$  este 1, se numește *nod aperiodic*, iar un lanț Markov care are toate nodurile aperiodice se numește *lanț Markov aperiodic*. Cel mai simplu exemplu de nod aperiodic este un nod  $i$  pentru care  $Q(i, i) > 0$ .

Evident că dacă matricea de tranziție are toate elementele de pe diagonala principală strict pozitive,  $Q(i, i) > 0$ , atunci lanțul este aperiodic.

Remarcăm faptul că proprietățile de ireductibilitate și aperiodicitate ale unui lanț Markov sunt proprietăți ale matricei de tranziție.

Se poate demonstra (algebric) următoarea proprietate:

**Propoziția 1.2.1** *Un lanț Markov ireductibil are toate nodurile de aceeași perioadă.*

Prin urmare, dacă un nod al unui lanț ireductibil este aperiodic, atunci toate nodurile sunt aperiodice. Astfel, pentru a arăta că un lanț ireductibil este aperiodic este suficient să identificăm un nod  $i$  pentru care  $Q(i, i) > 0$  (probabilitatea de trecere de la starea  $i$  la ea însăși este nenulă), pentru a concluziona că nodul  $i$  este aperiodic și deci toate stările lanțului sunt aperiodice. Dar există lanțuri ireductibile care nu au nici un nod  $i$  astfel încât  $Q(i, i) > 0$ , adică graful asociat nu conține nici o buclă, și totuși lanțul este aperiodic.

De exemplu pentru lanțul ce are matricea de tranziție:

$$Q = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

graful asociat nu are nici o buclă. Lanțul este ireductibil și nodul 4 aparține unui ciclu de lungime 2 și unuia de lungime 3. Cum cel mai mare divizor comun dintre 2 și 3 este 1, adică  $(2, 3) = 1$ , rezultă că nodul 4 este aperiodic și cum lanțul este ireductibil, atunci toate nodurile sunt aperiodice.

Se poate demonstra următorul rezultat, pe baza căruia s-a fundamentat și algoritmul PageRank–Google:

**Propoziția 1.2.2** *Dacă un lanț Markov pe  $S$  este ireductibil și aperiodic, atunci oricare ar fi distribuția inițială de probabilitate  $\pi_0$ , șirul distribuțiilor de probabilitate la momentul  $n$  asociat,  $(\pi_n)$ , este convergent și limita acestuia este un vector probabilist  $\pi$  care nu depinde de distribuția inițială de probabilitate (deci indiferent de distribuția inițială de probabilitate, șirurile asociate converg la aceeași limită  $\pi$ ). Această limită este unica distribuție de echilibru a lanțului Markov. Mai mult, șirul  $(Q^n)$  este convergent la o matrice de rang 1 având fiecare linie egală cu  $\pi^T$ :*

$$\lim_{n \rightarrow \infty} Q^n = \begin{pmatrix} \pi(1) & \pi(2) & \dots & \pi(m) \\ \pi(1) & \pi(2) & \dots & \pi(m) \\ \vdots & \vdots & \dots & \vdots \\ \pi(1) & \pi(2) & \dots & \pi(m) \end{pmatrix}.$$

Cum distribuția de echilibru  $\pi$  verifică relația  $\pi^T = \pi^T Q$ , ceea ce este echivalent, aplicând transpunerea, cu

$$Q^T \pi = \pi,$$

rezultă că  $\pi$  este **vector propriu probabilist al matricei  $Q^T$ , corespunzător valorii proprii 1.**

Acest rezultat matematic a influențat modul de definire al navigării aleatoare pe graful WEB, ca un lanț Markov ireductibil și aperiodic pe mulțimea paginilor WEB (vezi Material Suplimentar).