

# PS (curs 10 - S10)

## Inegalitatea Markov

Fie  $X$  o v.a. astfel încât  $X \geq 0$ , adică  $X$  ia valori nenegative. Dacă  $X$  are medie finită, atunci, pentru  $a > 0$ , avem

$$P(X \geq a) \leq \frac{M(X)}{a}.$$

Demo:

- $X \geq 0 \rightarrow P(X \geq 0) = 1$ , deci  $P(X < 0) = 0 = \int_{-\infty}^0 f(x) dx$ .

⇒ presupune că funcția  $f$  este zero pe întreg intervalul  $(-\infty, 0)$

■

$$\begin{aligned} M(X) &= \int_{-\infty}^{\infty} xf(x) dx = \underbrace{\int_{-\infty}^0 xf(x) dx}_{=0} + \int_0^a xf(x) dx \geq 0 + \int_a^{\infty} xf(x) dx \\ &\geq \int_a^{\infty} xf(x) dx. \end{aligned}$$

$$\blacksquare M(X) \geq \int_a^{\infty} af(x) dx = a \int_a^{\infty} f(x) dx = a \int_{[a, \infty)} f(x) dx = aP(X \geq a)$$

⇒  $M(X) \geq a P(X \geq a)$  q.e.d.

## Inegalitatea Cebîșev

Fie  $X$  o v.a. arbitrară de medie  $M(X)$  și dispersie  $\sigma^2(X)$  finite. Atunci:

$$P(|X - M(X)| \geq a) \leq \frac{\sigma^2(X)}{a^2}, \quad a > 0.$$

Demo:

- Fie variabila aleatoare  $Y = (X - M(X))^2 \geq 0$ ;
- Evident  $M(Y) = \sigma^2(X)$ ;
- inegalitatea Markov pentru v.a.  $Y$ :

$$P(|X - M(X)| \geq a) = P((X - M(X))^2 \geq a^2) = P(Y \geq a^2) \stackrel{\text{Markov}}{\leq} \frac{M(Y)}{a^2}.$$

- $M(Y) = \sigma^2(X)$ , rezultă inegalitatea Cebîșev.

Cazul  $a = k\sigma(X)$ ,  $k \in \mathbb{N}^*$ :

$$P(|X - M(X)| \geq a) \leq \frac{\sigma^2(X)}{k^2 \sigma^2(X)} = \frac{1}{k^2}.$$

Echivalent:

$$P(|X - M(X)| < k) = 1 - P(|X - M(X)| \geq k) \geq 1 - \frac{1}{k^2}.$$


- pentru  $k = 2$  avem:  $P(m - 2\sigma < X < m + 2\sigma) \geq 1 - \frac{1}{4} = 0.75$ .
- pentru  $k = 3$  avem  $P(m - 3\sigma < X < m + 3\sigma) \geq 1 - \frac{1}{9} = \frac{8}{9} = 0.88$ .
- pentru  $k = 4$  avem  
 $P(m - 4\sigma < X < m + 4\sigma) \geq 1 - \frac{1}{16} = \frac{15}{16} = 0.9375$ .

**Concluzie:** probabilitatea ca variabila aleatoare  $X$  să ia valori în intervale centrate în valoarea sa medie și de lungime  $4\sigma$ ,  $6\sigma$ ,  $8\sigma$  este mai mare decât 0.75, 0.88, respectiv 0.9375.

### Chebyshev's Inequality

*The proportion of observations within  $k$  standard deviations is at least  $1 - 1/k^2$*

No. Std Devs	$1 - 1/k^2$
1.5	0.56
2.0	0.75
3.0	0.89
4.0	0.94



## Covarianța

### Definiție

**Covarianța** variabilelor aleatoare  $X$  și  $Y$ , ce au mediile  $m_X = M(X)$ ,  $m_Y = M(Y)$  finite, este definită prin

$$\text{cov}(X, Y) = M((X - m_X)(Y - m_Y)).$$

### Observație:

- Covarianța = generalizare la două variabile a dispersiei

$$\text{cov}(X, X) = M((X - m_X)(X - m_X)) = M((X - m_X)^2) = \sigma^2(X).$$

- formula mai simplă de calcul

$$\text{cov}(X, Y) = M(XY) - M(X)M(Y)$$

**Variabile aleatoare necorelate:**  $\text{cov}(X, Y) = 0$ .

## Definiție

**Coeficientul de corelație** a două variabile aleatoare  $X$  și  $Y$ , de abateri standard nenule, este un număr real, notat cu  $\rho(X, Y)$ , definit prin

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y},$$

unde  $\sigma_X, \sigma_Y$  – abaterile standard ale variabilelor aleatoare  $X$ , respectiv  $Y$ .

- dacă  $Z_1 = \frac{X - m_X}{\sigma_X}$ ,  $Z_2 = \frac{Y - m_Y}{\sigma_Y}$ , atunci

$$\rho(X, Y) = \text{cov}(Z_1, Z_2)$$

- $\rho(X, Y) \in [-1, 1]$ .

## Proprietate

Dacă între variabilele aleatoare  $X$  și  $Y$  există o relație liniară de forma

$$Y = aX + b, \quad a, b \in \mathbb{R}, \quad a \neq 0,$$

atunci

$$\rho(X, Y) = \begin{cases} -1, & \text{dacă } a < 0, \\ 1, & \text{dacă } a > 0. \end{cases}$$

Reciproc, dacă  $|\rho(X, Y)| = 1$ , atunci între ele există o relație liniară,

$$Y = aX + b, \quad a \neq 0$$

În concluzie:

- $\rho(X, Y) = 0$ , atunci  $X$  și  $Y$  sunt **necorelate**;
- $\rho(X, Y)$  este apropiat de zero, atunci  $X$  și  $Y$  sunt **slab corelate** (intensitatea legăturii dintre ele este redusă);
- $\rho(X, Y) = 1$ , atunci  $Y = aX + b$ ,  $a > 0$ ,  $X$  și  $Y$  sunt **pozitiv corelate**;
- $\rho(X, Y) = -1$ , atunci  $Y = aX + b$ ,  $a < 0$ ,  $X$  și  $Y$  sunt **negativ corelate**;
- $|\rho(X, Y)|$  are o valoare apropiată de 1, **relația dintre variabilele aleatoare este "aproape liniară"**, adică valorile  $(x, y)$  ale vectorului aleator  $(X, Y)$  sunt ușor dispersate în jurul unei drepte de ecuație  $y = ax + b$ .

## Matricea de covarianță

### Definiție

**Matricea de covarianță** a vectorului aleator  $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$  este matricea notată cu  $\Sigma$ , ale cărei elemente sunt  $\sigma_{ij} = \text{cov}(X_i, X_j)$ ,  $i, j \in \{1, \dots, n\}$ .

### Observații:

- $\sigma_{ii} = \text{cov}(X_i, X_i) = \sigma^2(X_i)$
- $\Sigma$  este simetrică și semipozitiv definită
- $\Sigma = M(\mathbf{Y}\mathbf{Y}^T)$ , unde  $\mathbf{Y} = \mathbf{X} - \mathbf{m} = (X_1 - m_1, X_2 - m_2, \dots, X_n - m_n)^T$  iar  $M(\mathbf{Y}\mathbf{Y}^T)$  notează matricea mediilor elementelor matricii  $\mathbf{Y}\mathbf{Y}^T$ .

## Mixturi de probabilitate

Fie  $p_1, p_2, \dots, p_n \in (0, 1)$  astfel încât  $p_1 + p_2 + \dots + p_n = 1$ .

- Dacă  $F_1, F_2, \dots, F_n$  sunt funcțiile de repartiție ale variabilelor aleatoare  $X_1, X_2, \dots, X_n$ , atunci funcția

$$F = p_1 F_1 + p_2 F_2 + \dots + p_n F_n$$

este o funcție de repartiție, numită **repartiție compusă**.

- Dacă  $f_1, f_2, \dots, f_n$  sunt densitățile de probabilitate ale variabilelor aleatoare  $X_1, X_2, \dots, X_n$ , atunci

$$f = p_1 f_1 + p_2 f_2 + \dots + p_n f_n$$

este o densitate de probabilitate, numită **densitate compusă**.

### Definiție

O variabilă aleatoare  $X$  ce are densitatea de probabilitate compusă  $f$  sau funcția de repartiție compusă  $F$ , se numește **mixtură de distribuții de probabilitate** sau, mai simplu, **mixtură de probabilitate**.

- Dacă  $X$  este o v.a. cu densitatea  $f = p_1 f_1 + p_2 f_2 + \dots + p_n f_n \iff X$  are densitatea  $f_1$  cu probab.  $p_1$ , ...,  $X$  are densitatea  $f_n$  cu probab.  $p_n$ .
- Reprezentând fiecare densitate  $f_k$  prin indicele său  $k$ , asociem unei densități compuse o variabilă aleatoare discretă:

$$H = \begin{pmatrix} 1 & 2 & \dots & k & \dots & n \\ p_1 & p_2 & \dots & p_k & \dots & p_n \end{pmatrix}.$$

## Definiție

O v.a.  $X$  a cărei densitate de probabilitate

$$f = p_1 f_1 + p_2 f_2 + \dots + p_n f_n, \text{ unde } f_i(x) = \begin{cases} \frac{1}{\theta_i} e^{-x/\theta_i}, & \text{dacă } x \geq 0, \\ 0, & \text{dacă } x < 0, \end{cases}$$

este compusa a  $n$  densități ale distribuției exponențiale de parametri  $\theta_1, \theta_2, \dots, \theta_n$  se numește **variabilă aleatoare hiperexponențială**.

Variabilele aleat. hiperexponențiale modelează durata serviciului procesorului. Se folosesc în simularea rețelelor de cozi.

## Mixura Poisson



Universitatea Politehnică Timișoara

### Exemplu:

Facebook monitorizează atitudinea unui user față de postările pe wall-uri și îi asociază un număr de reacții ce sunt modelate de o mixtură Poisson.

- reacția  $R_1$  (cu prob.  $p_1$ ) = linkuri la articole din *Times New Roman* cu rata  $\lambda_1$ /oră
- reacția  $R_2$  (cu prob.  $p_2$ ) = like-uri la pozele amicilor, cu rata  $\lambda_2$ /oră

Astfel, numărul de reacții/manifestări ale userului pe oră este o variabilă aleatoare  $X$  ce are ca distribuție de probabilitate mixtura Poisson:

$$P_X(k) := P(X = k) = p_1 e^{-\lambda_1} \frac{\lambda_1^k}{k!} + p_2 e^{-\lambda_2} \frac{\lambda_2^k}{k!}.$$

Mixtura de distribuții de probabilitate **nu** înseamnă că variabila  $X$  este de forma  $X = p_1 X_1 + p_2 X_2$ , cu  $X_i \sim \text{Poiss}(\lambda_i)$ ,  $i = 1, 2$ , ci că  $X$  are distribuția Poisson de rată  $\lambda_1$  cu probab.  $p_1$ , respectiv  $X$  are distribuția Poisson de rată  $\lambda_2$  cu probab.  $p_2$ .